PROYECTO: Mantenimiento Predictivo — Línea de Manufactura

Dataset: AI4I 2020 Predictive Maintenance

```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import warnings
warnings.filterwarnings('ignore')

plt.rcParams['figure.figsize'] = (12, 5)
plt.rcParams['font.family'] = 'DejaVu Sans'
sns.set_theme(style="whitegrid", palette="muted")

print("✅ Librerías cargadas correctamente")
```

```
✅ Librerías cargadas correctamente
```

```python
from google.colab import files
uploaded = files.upload()

df = pd.read_csv('/content/ai4i2020.csv')
print(f"✅ Dataset cargado: {df.shape[0]} filas x {df.shape[1]} columnas")
```

Elegir archivos ai4i2020.csv

ai4i2020.csv(text/csv) - 522048 bytes, last modified: 23/3/2026 - 100% done

```
Saving ai4i2020.csv to ai4i2020 (1).csv
✅ Dataset cargado: 10000 filas x 14 columnas
```

```python
print("=" * 55)
print("INSPECCIÓN INICIAL DEL DATASET")
print("=" * 55)

print("\n--- Primeras 5 filas ---")
display(df.head())

print("\n--- Tipos de datos y valores nulos ---")
info = pd.DataFrame({
    'Tipo': df.dtypes,
    'Nulos': df.isnull().sum(),
    '% Nulos': (df.isnull().sum() / len(df) * 100).round(2),
    'Únicos': df.nunique()
})
display(info)

print("\n--- Estadísticas descriptivas ---")
display(df.describe().round(2))
```

```
--- Primeras 5 filas ---
```

	UDI	Product ID	Type	Air temperature [K]	Process temperature [K]	Rotational speed [rpm]	Torque [Nm]	Tool wear [min]	Machine failure	TWF	HDF	PWF	OSF	RNF
0	1	M14860	M	298.1	308.6	1551	42.8	0	0	0	0	0	0	0
1	2	L47181	L	298.2	308.7	1408	46.3	3	0	0	0	0	0	0
2	3	L47182	L	298.1	308.5	1498	49.4	5	0	0	0	0	0	0
3	4	L47183	L	298.2	308.6	1433	39.5	7	0	0	0	0	0	0
4	5	L47184	L	298.2	308.7	1408	40.0	9	0	0	0	0	0	0

```
--- Tipos de datos y valores nulos ---
```

	Tipo	Nulos	% Nulos	Únicos
UDI	int64	0	0.0	10000
Product ID	object	0	0.0	10000
Type	object	0	0.0	3
Air temperature [K]	float64	0	0.0	93
Process temperature [K]	float64	0	0.0	82
Rotational speed [rpm]	int64	0	0.0	941
Torque [Nm]	float64	0	0.0	577
Tool wear [min]	int64	0	0.0	246
Machine failure	int64	0	0.0	2
TWF	int64	0	0.0	2
HDF	int64	0	0.0	2
PWF	int64	0	0.0	2
OSF	int64	0	0.0	2
RNF	int64	0	0.0	2

```
--- Estadísticas descriptivas ---
```

	UDI	Air temperature [K]	Process temperature [K]	Rotational speed [rpm]	Torque [Nm]	Tool wear [min]	Machine failure	TWF	HDF	PWF	OSF	RI
count	10000.00	10000.0	10000.00	10000.00	10000.00	10000.00	10000.00	10000.00	10000.00	10000.00	10000.00	10000.(
mean	5000.50	300.0	310.01	1538.78	39.99	107.95	0.03	0.00	0.01	0.01	0.01	0.(
std	2886.90	2.0	1.48	179.28	9.97	63.65	0.18	0.07	0.11	0.10	0.10	0.(
min	1.00	295.3	305.70	1168.00	3.80	0.00	0.00	0.00	0.00	0.00	0.00	0.(
25%	2500.75	298.3	308.80	1423.00	33.20	53.00	0.00	0.00	0.00	0.00	0.00	0.(
50%	5000.50	300.1	310.10	1503.00	40.10	108.00	0.00	0.00	0.00	0.00	0.00	0.(
75%	7500.25	301.5	311.10	1612.00	46.80	162.00	0.00	0.00	0.00	0.00	0.00	0.(
max	10000.00	304.5	313.80	2886.00	76.60	253.00	1.00	1.00	1.00	1.00	1.00	1.(

Pasos siguientes: Generar código con info New interactive sheet

```
print("=" * 55)
print("DISTRIBUCIÓN DE FALLAS (Variable objetivo)")
print("=" * 55)

fallas = df['Machine failure'].value_counts()
pct = df['Machine failure'].value_counts(normalize=True) * 100

resumen = pd.DataFrame({
    'Cantidad': fallas,
    'Porcentaje': pct.round(2)
})
resumen.index = ['Sin falla (0)', 'Con falla (1)']
display(resumen)

```

```
fig, axes = plt.subplots(1, 2, figsize=(12, 4))

axes[0].bar(['Sin falla', 'Con falla'], fallas.values,
            color=['#4C9BE8', '#E85D4C'], edgecolor='white', linewidth=1.5)
axes[0].set_title('Distribución de fallas en la línea', fontweight='bold')
axes[0].set_ylabel('Cantidad de registros')
for i, v in enumerate(fallas.values):
    axes[0].text(i, v + 20, str(v), ha='center', fontweight='bold')

axes[1].pie(fallas.values, labels=['Sin falla', 'Con falla'],
            colors=['#4C9BE8', '#E85D4C'], autopct='%1.1f%%',
            startangle=90, wedgeprops={'edgecolor': 'white', 'linewidth': 2})
axes[1].set_title('Proporción de fallas', fontweight='bold')

plt.suptitle('AI4I 2020 — Vista general de fallas', fontsize=13, fontweight='bold', y=1.02)
plt.tight_layout()
plt.savefig('01_distribucion_fallas.png', dpi=150, bbox_inches='tight')
plt.show()
print("✅ Gráfico guardado como 01_distribucion_fallas.png")
```

```
========================================================
DISTRIBUCIÓN DE FALLAS (Variable objetivo)
========================================================
```

	Cantidad	Porcentaje
Sin falla (0)	9661	96.61
Con falla (1)	339	3.39

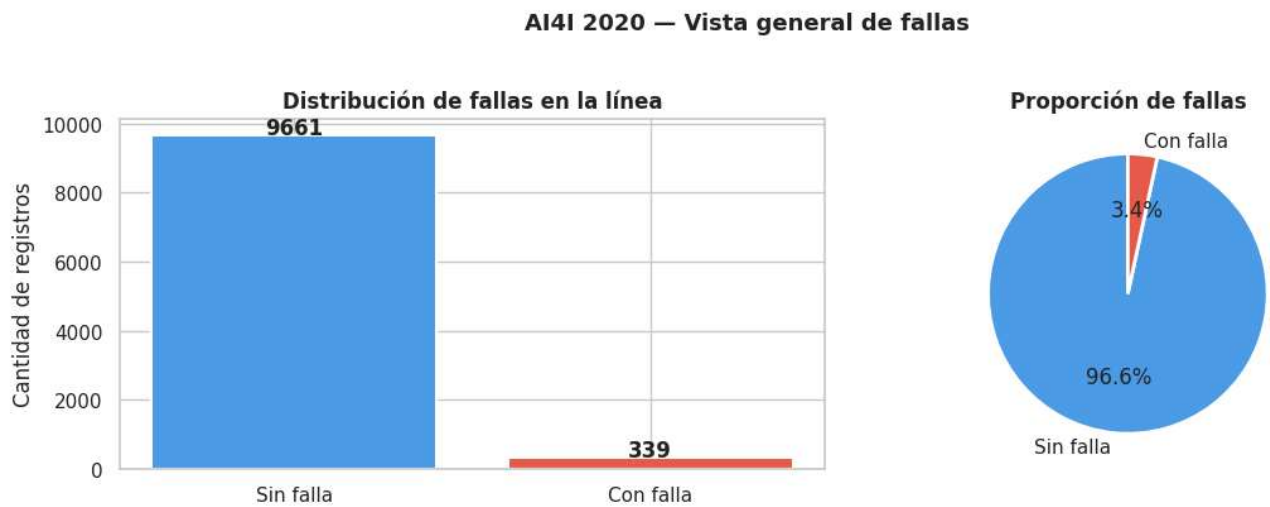

✅ Gráfico guardado como 01_distribucion_fallas.png

Pasos siguientes: Generar código con resumen | New interactive sheet

Análisis Exploratorio de Datos (EDA)

```
df.columns = [
    'UDI', 'product_id', 'type', 'air_temp', 'process_temp',
    'rot_speed', 'torque', 'tool_wear', 'failure',
    'TWF', 'HDF', 'PWF', 'OSF', 'RNF'
]

print("✅ Columnas renombradas:")
print(df.columns.tolist())
```

```
✅ Columnas renombradas:
['UDI', 'product_id', 'type', 'air_temp', 'process_temp', 'rot_speed', 'torque', 'tool_wear', 'failure', 'TWF', 'HDF', 'PWF', 'O
```

```
# Tipos de falla y su frecuencia
tipos_falla = ['TWF', 'HDF', 'PWF', 'OSF', 'RNF']
conteos = df[tipos_falla].sum().sort_values(ascending=False)

fig, ax = plt.subplots(figsize=(10, 4))
```

```
bars = ax.bar(conteos.index, conteos.values,
              color=['#E85D4C','#E8944C','#E8C44C','#4CAF8E','#4C9BE8'],
              edgecolor='white', linewidth=1.5)
ax.set_title('Frecuencia por tipo de falla', fontweight='bold', fontsize=13)
ax.set_ylabel('Cantidad de ocurrencias')
for bar, val in zip(bars, conteos.values):
    ax.text(bar.get_x() + bar.get_width()/2, bar.get_height() + 1,
            str(val), ha='center', fontweight='bold')

# Etiquetas descriptivas
labels = {
    'HDF': 'HDF\nCalor disipación',
    'PWF': 'PWF\nFalla potencia',
    'OSF': 'OSF\nSobrecarga',
    'TWF': 'TWF\nDesgaste herram.',
    'RNF': 'RNF\nFalla aleatoria'
}
ax.set_xticklabels([labels[t] for t in conteos.index], fontsize=9)
plt.tight_layout()
plt.savefig('02_tipos_falla.png', dpi=150, bbox_inches='tight')
plt.show()
```

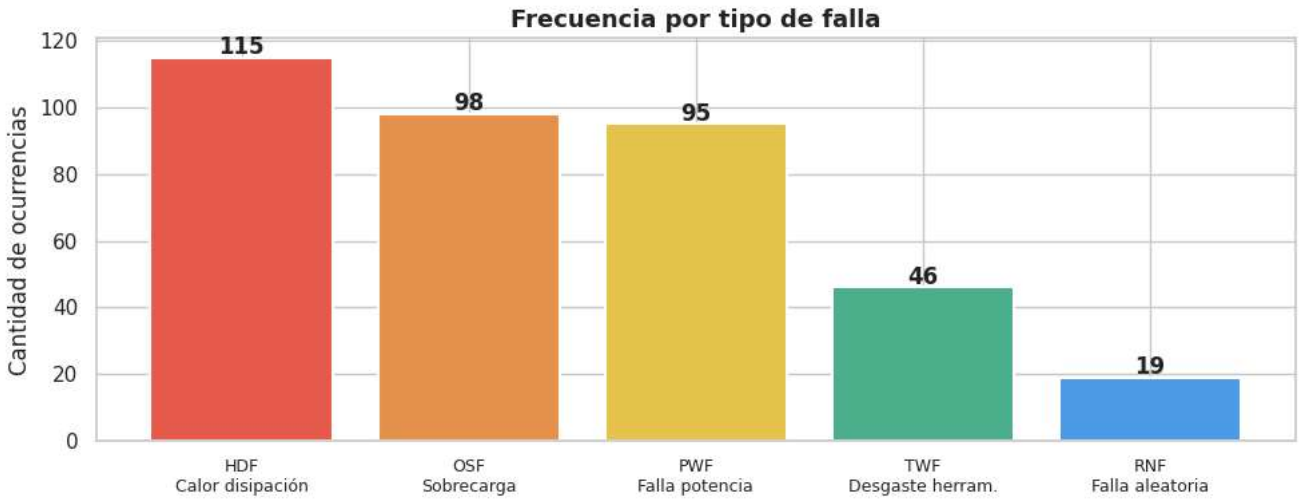


```
# Distribución de cada sensor por estado (falla vs no falla)
sensores = ['air_temp', 'process_temp', 'rot_speed', 'torque', 'tool_wear']
nombres = ['Temp. aire [K]', 'Temp. proceso [K]',
           'Vel. rotacional [rpm]', 'Torque [Nm]', 'Desgaste herram. [min]']

fig, axes = plt.subplots(2, 3, figsize=(15, 8))
axes = axes.flatten()

for i, (col, nombre) in enumerate(zip(sensores, nombres)):
    sin_falla = df[df['failure'] == 0][col]
    con_falla = df[df['failure'] == 1][col]

    axes[i].hist(sin_falla, bins=40, alpha=0.6, color='#4C9BE8', label='Sin falla', density=True)
    axes[i].hist(con_falla, bins=40, alpha=0.7, color='#E85D4C', label='Con falla', density=True)
    axes[i].set_title(nombre, fontweight='bold')
    axes[i].set_ylabel('Densidad')
    axes[i].legend(fontsize=8)

axes[5].axis('off')
plt.suptitle('Distribución de sensores: falla vs sin falla', fontsize=13, fontweight='bold')
plt.tight_layout()
plt.savefig('03_distribucion_sensores.png', dpi=150, bbox_inches='tight')
plt.show()
```

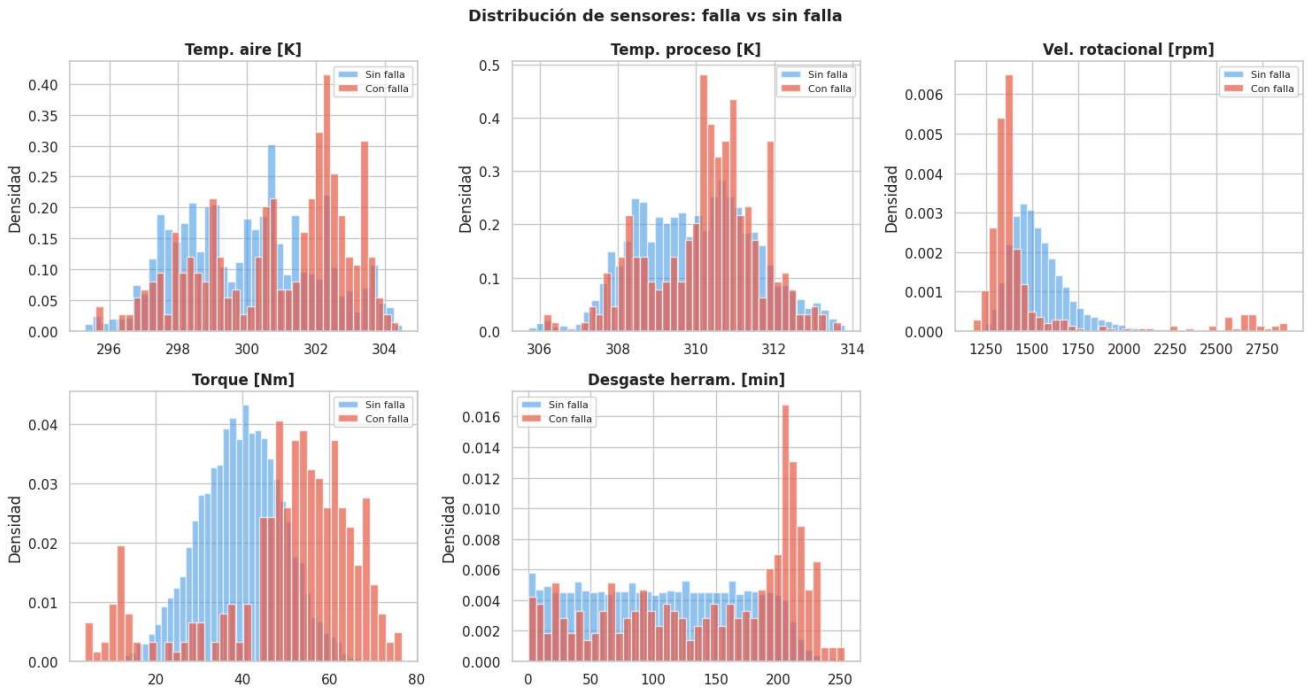


```python
# Mapa de correlación
cols_numericas = ['air_temp', 'process_temp', 'rot_speed', 'torque', 'tool_wear', 'failure']
corr = df[cols_numericas].corr()

fig, ax = plt.subplots(figsize=(8, 6))
mask = np.triu(np.ones_like(corr, dtype=bool))
sns.heatmap(corr, mask=mask, annot=True, fmt='.2f', cmap='RdYlBu_r',
            center=0, ax=ax, linewidths=0.5,
            cbar_kws={'label': 'Correlación'})
ax.set_title('Correlación entre variables del proceso', fontweight='bold', fontsize=13)
plt.tight_layout()
plt.savefig('04_correlacion.png', dpi=150, bbox_inches='tight')
plt.show()
```

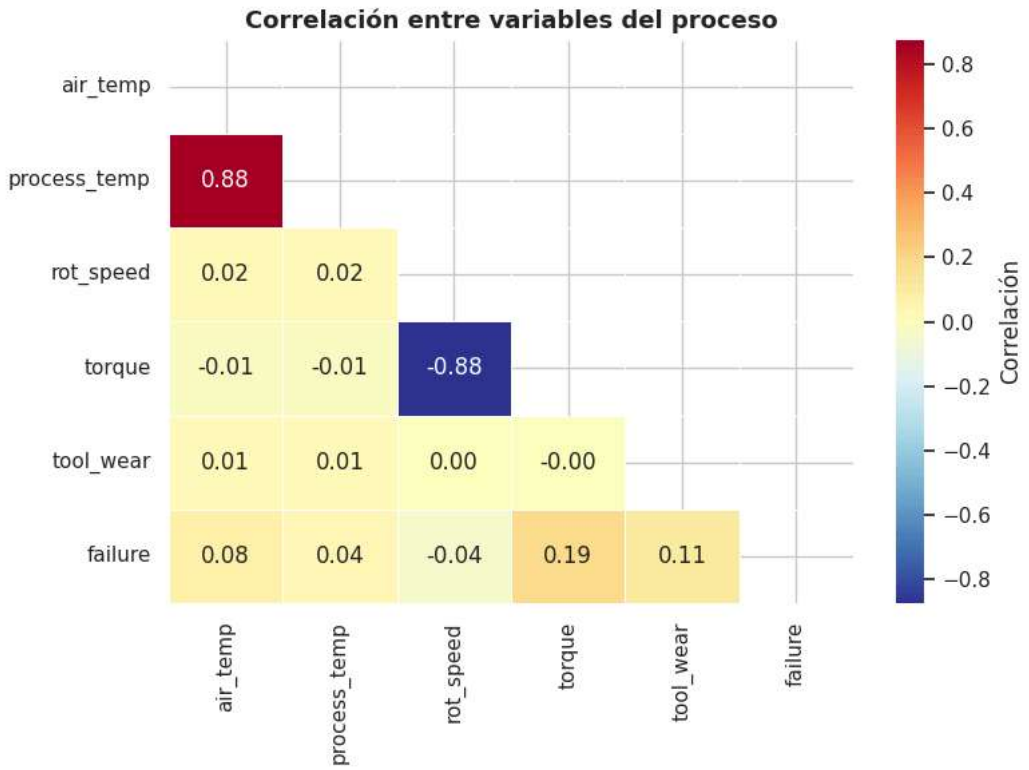


```python
# Tasa de falla según tipo de producto (L = Low, M = Medium, H = High quality)
falla_por_tipo = df.groupby('type')['failure'].agg(['sum', 'count', 'mean'])
falla_por_tipo.columns = ['Fallas', 'Total', 'Tasa']
falla_por_tipo['Tasa %'] = (falla_por_tipo['Tasa'] * 100).round(2)
falla_por_tipo.index = ['Alta calidad (H)', 'Baja calidad (L)', 'Media calidad (M)']

print("=" * 45)
print("TASA DE FALLA POR TIPO DE PRODUCTO")
print("=" * 45)
display(falla_por_tipo)

fig, ax = plt.subplots(figsize=(8, 4))
colors = ['#4CAF8E', '#4C9BE8', '#9B7BE8']
bars = ax.bar(falla_por_tipo.index, falla_por_tipo['Tasa %'],
              color=colors, edgecolor='white', linewidth=1.5)
ax.set_title('Tasa de falla por tipo de producto', fontweight='bold', fontsize=13)
ax.set_ylabel('Tasa de falla (%)')
for bar, val in zip(bars, falla_por_tipo['Tasa %']):
    ax.text(bar.get_x() + bar.get_width()/2, bar.get_height() + 0.05,
            f'{val}%', ha='center', fontweight='bold')
plt.tight_layout()
plt.savefig('05_falla_por_tipo.png', dpi=150, bbox_inches='tight')
plt.show()
```

```
============================================
TASA DE FALLA POR TIPO DE PRODUCTO
============================================
```

	Fallas	Total	Tasa	Tasa %
Alta calidad (H)	21	1003	0.020937	2.09
Baja calidad (L)	235	6000	0.039167	3.92
Media calidad (M)	83	2997	0.027694	2.77

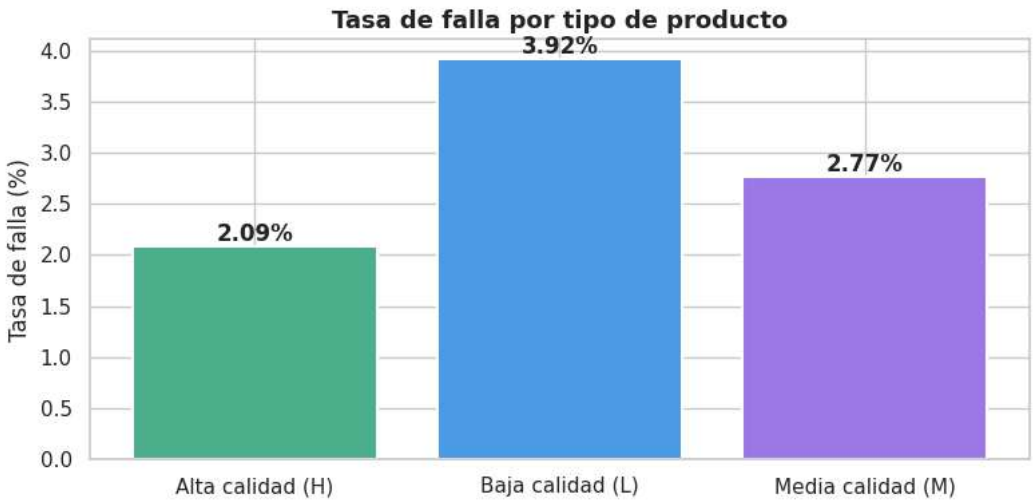

Pasos siguientes: Generar código con `falla_por_tipo` New interactive sheet

INGENIERÍA DE FEATURES

```
df_model = df.copy()

# Feature 1: Diferencia de temperaturas
# La física del HDF dice que si (process_temp - air_temp) es muy alto,
# el sistema no está disipando calor correctamente
df_model['temp_diff'] = df_model['process_temp'] - df_model['air_temp']

# Feature 2: Potencia mecánica (torque × velocidad angular)
# Identifica condiciones de sobrecarga — relacionado con PWF y OSF
df_model['power'] = df_model['torque'] * df_model['rot_speed']

# Feature 3: Estrés mecánico (torque / velocidad)
# Alta cuando la máquina trabaja lento bajo carga — señal de desgaste
df_model['mech_stress'] = df_model['torque'] / (df_model['rot_speed'] + 1)

# Feature 4: Desgaste acumulado × torque
# Combina dos señales de deterioro — herramienta gastada bajo alta carga
df_model['wear_torque'] = df_model['tool_wear'] * df_model['torque']

# Feature 5: Codificar el tipo de producto
df_model['type_encoded'] = df_model['type'].map({'L': 0, 'M': 1, 'H': 2})

# Verificación
nuevos_features = ['temp_diff', 'power', 'mech_stress', 'wear_torque', 'type_encoded']
print("✅ Features creados:")
display(df_model[nuevos_features + ['failure']].describe().round(3))
```

Features creados:

	temp_diff	power	mech_stress	wear_torque	type_encoded	failure
count	10000.000	10000.000	10000.000	10000.000	10000.000	10000.000
mean	10.001	59967.147	0.027	4314.665	0.500	0.034
std	1.001	10193.094	0.009	2826.568	0.671	0.181
min	7.600	10966.800	0.001	0.000	0.000	0.000
25%	9.300	53105.400	0.021	1963.650	0.000	0.000
50%	9.800	59883.900	0.027	4012.950	0.000	0.000
75%	11.000	66873.750	0.033	6279.000	1.000	0.000
max	12.100	99980.400	0.064	16497.000	2.000	1.000

```python
# Comparar los nuevos features entre máquinas con y sin falla
fig, axes = plt.subplots(1, 4, figsize=(16, 4))

features_nuevos = ['temp_diff', 'power', 'mech_stress', 'wear_torque']
nombres_nuevos = ['Diferencia térmica', 'Potencia mecánica',
                  'Estrés mecánico', 'Desgaste × Torque']

for i, (feat, nombre) in enumerate(zip(features_nuevos, nombres_nuevos)):
    sin = df_model[df_model['failure'] == 0][feat]
    con = df_model[df_model['failure'] == 1][feat]
    axes[i].hist(sin, bins=40, alpha=0.6, color='#4C9BE8', label='Sin falla', density=True)
    axes[i].hist(con, bins=40, alpha=0.7, color='#E85D4C', label='Con falla', density=True)
    axes[i].set_title(nombre, fontweight='bold', fontsize=10)
    axes[i].legend(fontsize=8)

plt.suptitle('Poder discriminativo de los nuevos features', fontsize=13, fontweight='bold')
plt.tight_layout()
plt.savefig('06_nuevos_features.png', dpi=150, bbox_inches='tight')
plt.show()
```

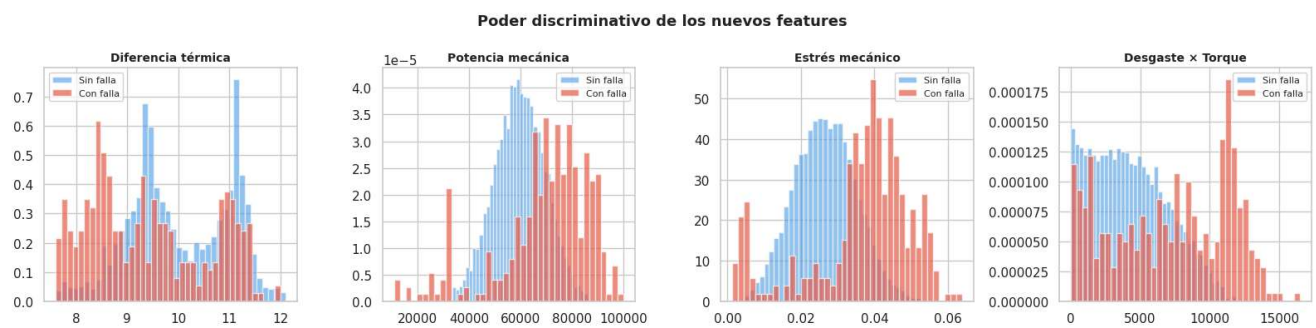


```python
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler

# Definir features finales y variable objetivo
FEATURES = [
    'air_temp', 'process_temp', 'rot_speed', 'torque', 'tool_wear',
    'temp_diff', 'power', 'mech_stress', 'wear_torque', 'type_encoded'
]
TARGET = 'failure'

X = df_model[FEATURES]
y = df_model[TARGET]

# División train/test — 80% entrenamiento, 20% prueba
# stratify=y garantiza que ambos conjuntos tengan la misma proporción de fallas
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

```

```
# Escalar los features (necesario para algunos modelos)
scaler = StandardScaler()
X_train_sc = scaler.fit_transform(X_train)
X_test_sc = scaler.transform(X_test)  # Ojo: solo transform, nunca fit en test

print("=" * 45)
print("RESUMEN DE LA PARTICIÓN")
print("=" * 45)
print(f"Entrenamiento : {X_train.shape[0]:,} registros")
print(f"Prueba        : {X_test.shape[0]:,} registros")
print(f"\nFallas en entrenamiento : {y_train.sum()} ({y_train.mean()*100:.1f}%)")
print(f"Fallas en prueba        : {y_test.sum()} ({y_test.mean()*100:.1f}%)")
print("\n✅ Partición estratificada correcta")
```

```
=============================================
RESUMEN DE LA PARTICIÓN
=============================================
Entrenamiento : 8,000 registros
Prueba        : 2,000 registros

Fallas en entrenamiento : 271 (3.4%)
Fallas en prueba        : 68 (3.4%)

✅ Partición estratificada correcta
```

```
# SMOTE genera ejemplos sintéticos de la clase minoritaria (fallas)
# Es la técnica estándar en industria para este tipo de problema
try:
    from imblearn.over_sampling import SMOTE
except ImportError:
    !pip install imbalanced-learn -q
    from imblearn.over_sampling import SMOTE

smote = SMOTE(random_state=42)
X_train_bal, y_train_bal = smote.fit_resample(X_train_sc, y_train)

print("=" * 45)
print("ANTES Y DESPUÉS DE SMOTE")
print("=" * 45)
print(f"Antes  — Sin falla: {(y_train==0).sum():,} | Con falla: {(y_train==1).sum():,}")
print(f"Después — Sin falla: {(y_train_bal==0).sum():,} | Con falla: {(y_train_bal==1).sum():,}")
print("\n✅ Clases balanceadas para entrenamiento")
```

```
=============================================
ANTES Y DESPUÉS DE SMOTE
=============================================
Antes  — Sin falla: 7,729 | Con falla: 271
Después — Sin falla: 7,729 | Con falla: 7,729

✅ Clases balanceadas para entrenamiento
```

ENTRENAMIENTO Y EVALUACIÓN DE MODELOS

```
from sklearn.ensemble import RandomForestClassifier, GradientBoostingClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import (classification_report, confusion_matrix,
                             roc_auc_score, roc_curve, precision_recall_curve,
                             average_precision_score)
import time

modelos = {
    'Logistic Regression': LogisticRegression(random_state=42, max_iter=1000),
    'Random Forest':       RandomForestClassifier(n_estimators=100, random_state=42, n_jobs=-1),
    'Gradient Boosting':   GradientBoostingClassifier(n_estimators=100, random_state=42)
}

resultados = {}

print("=" * 55)
print("ENTRENAMIENTO DE MODELOS")
print("=" * 55)

for nombre, modelo in modelos.items():
    inicio = time.time()
    modelo.fit(X_train_bal, y_train_bal)
```

```
    tiempo = round(time.time() - inicio, 2)

    y_pred  = modelo.predict(X_test_sc)
    y_proba = modelo.predict_proba(X_test_sc)[:, 1]

    roc_auc = roc_auc_score(y_test, y_proba)
    ap      = average_precision_score(y_test, y_proba)

    resultados[nombre] = {
        'modelo':  modelo,
        'y_pred':  y_pred,
        'y_proba': y_proba,
        'roc_auc': roc_auc,
        'ap':      ap,
        'tiempo':  tiempo
    }
    print(f"\n{nombre}")
    print(f"  ROC-AUC : {roc_auc:.4f}  |  Avg Precision : {ap:.4f}  |  Tiempo: {tiempo}s")

print("\n✅ Modelos entrenados")
```

```
=======================================================
ENTRENAMIENTO DE MODELOS
=======================================================

Logistic Regression
  ROC-AUC : 0.9394  |  Avg Precision : 0.4169  |  Tiempo: 0.07s

Random Forest
  ROC-AUC : 0.9837  |  Avg Precision : 0.8496  |  Tiempo: 6.19s

Gradient Boosting
  ROC-AUC : 0.9786  |  Avg Precision : 0.8555  |  Tiempo: 12.82s

✅ Modelos entrenados
```

```
from sklearn.metrics import precision_score, recall_score, f1_score

filas = []
for nombre, r in resultados.items():
    filas.append({
        'Modelo':      nombre,
        'ROC-AUC':     round(r['roc_auc'], 4),
        'Avg Prec.':   round(r['ap'], 4),
        'Precision':   round(precision_score(y_test, r['y_pred']), 4),
        'Recall':      round(recall_score(y_test, r['y_pred']), 4),
        'F1-Score':    round(f1_score(y_test, r['y_pred']), 4),
        'Tiempo (s)':  r['tiempo']
    })

df_resultados = pd.DataFrame(filas).set_index('Modelo')
display(df_resultados)

# Identificar el mejor modelo por ROC-AUC
mejor_nombre = df_resultados['ROC-AUC'].idxmax()
print(f"\n🏆 Mejor modelo: {mejor_nombre} (ROC-AUC: {df_resultados.loc[mejor_nombre, 'ROC-AUC']})")
```

Modelo	ROC-AUC	Avg Prec.	Precision	Recall	F1-Score	Tiempo (s)
Logistic Regression	0.9394	0.4169	0.1802	0.8824	0.2993	0.07
Random Forest	0.9837	0.8496	0.6129	0.8382	0.7081	6.19
Gradient Boosting	0.9786	0.8555	0.3910	0.8971	0.5446	12.82

```
🏆 Mejor modelo: Random Forest (ROC-AUC: 0.9837)
```

Pasos siguientes: Generar código con df_resultados | New interactive sheet

```
colores = ['#9B7BE8', '#4C9BE8', '#E85D4C']

fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# Curva ROC
for (nombre, r), color in zip(resultados.items(), colores):
    fpr, tpr, _ = roc_curve(y_test, r['y_proba'])
```

```
    axes[0].plot(fpr, tpr, color=color, linewidth=2,
                 label=f"{nombre} (AUC={r['roc_auc']:.3f})")
axes[0].plot([0,1],[0,1], 'k--', linewidth=1, alpha=0.5, label='Aleatorio')
axes[0].set_xlabel('Tasa de Falsos Positivos')
axes[0].set_ylabel('Tasa de Verdaderos Positivos')
axes[0].set_title('Curva ROC — Comparación de modelos', fontweight='bold')
axes[0].legend(fontsize=9)
axes[0].fill_between([0,1],[0,1], alpha=0.05, color='gray')

# Curva Precision-Recall (más relevante con clases desbalanceadas)
for (nombre, r), color in zip(resultados.items(), colores):
    prec, rec, _ = precision_recall_curve(y_test, r['y_proba'])
    axes[1].plot(rec, prec, color=color, linewidth=2,
                 label=f"{nombre} (AP={r['ap']:.3f})")
axes[1].set_xlabel('Recall')
axes[1].set_ylabel('Precision')
axes[1].set_title('Curva Precision-Recall', fontweight='bold')
axes[1].legend(fontsize=9)

plt.suptitle('Evaluación de modelos — Mantenimiento Predictivo', fontsize=13, fontweight='bold')
plt.tight_layout()
plt.savefig('07_curvas_roc.png', dpi=150, bbox_inches='tight')
plt.show()
```

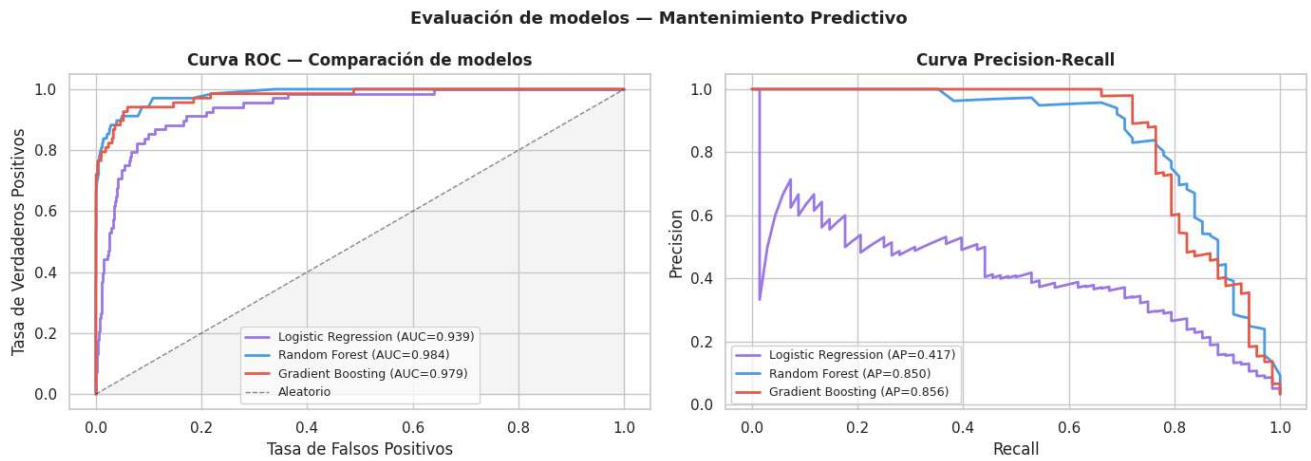


```
mejor = resultados[mejor_nombre]

fig, axes = plt.subplots(1, 2, figsize=(13, 5))

# Matriz de confusión
cm = confusion_matrix(y_test, mejor['y_pred'])
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues', ax=axes[0],
            xticklabels=['Sin falla', 'Con falla'],
            yticklabels=['Sin falla', 'Con falla'],
            linewidths=1, linecolor='white', cbar=False)
axes[0].set_title(f'Matriz de confusión\n{mejor_nombre}', fontweight='bold')
axes[0].set_ylabel('Real')
axes[0].set_xlabel('Predicho')

# Anotar las 4 celdas con etiquetas
tn, fp, fn, tp = cm.ravel()
axes[0].text(0.5, 0.35, 'TN', color='gray', ha='center', fontsize=9)
axes[0].text(1.5, 0.35, 'FP', color='#E85D4C', ha='center', fontsize=9)
axes[0].text(0.5, 1.35, 'FN', color='#E8944C', ha='center', fontsize=9)
axes[0].text(1.5, 1.35, 'TP', color='#4CAF8E', ha='center', fontsize=9)

# Reporte de clasificación como gráfico de barras
reporte = classification_report(y_test, mejor['y_pred'],
                                target_names=['Sin falla','Con falla'],
                                output_dict=True)
metricas = pd.DataFrame(reporte).T.iloc[:2][['precision','recall','f1-score']]
```

```
metricas.plot(kind='bar', ax=axes[1], color=['#4C9BE8','#4CAF8E','#9B7BE8'],
              edgecolor='white', linewidth=1)
axes[1].set_title(f'Métricas por clase\n{mejor_nombre}', fontweight='bold')
axes[1].set_ylabel('Score')
axes[1].set_xticklabels(['Sin falla', 'Con falla'], rotation=0)
axes[1].legend(['Precision', 'Recall', 'F1-Score'])
axes[1].set_ylim(0, 1.1)
for container in axes[1].containers:
    axes[1].bar_label(container, fmt='%.2f', fontsize=8, padding=2)

plt.tight_layout()
plt.savefig('08_confusion_matrix.png', dpi=150, bbox_inches='tight')
plt.show()

print(f"\n📊 Resumen del mejor modelo ({mejor_nombre}):")
print(f"   Verdaderos Positivos (fallas detectadas) : {tp}")
print(f"   Falsos Negativos (fallas no detectadas)  : {fn}  ← el más costoso")
print(f"   Falsos Positivos (falsas alarmas)         : {fp}")
```

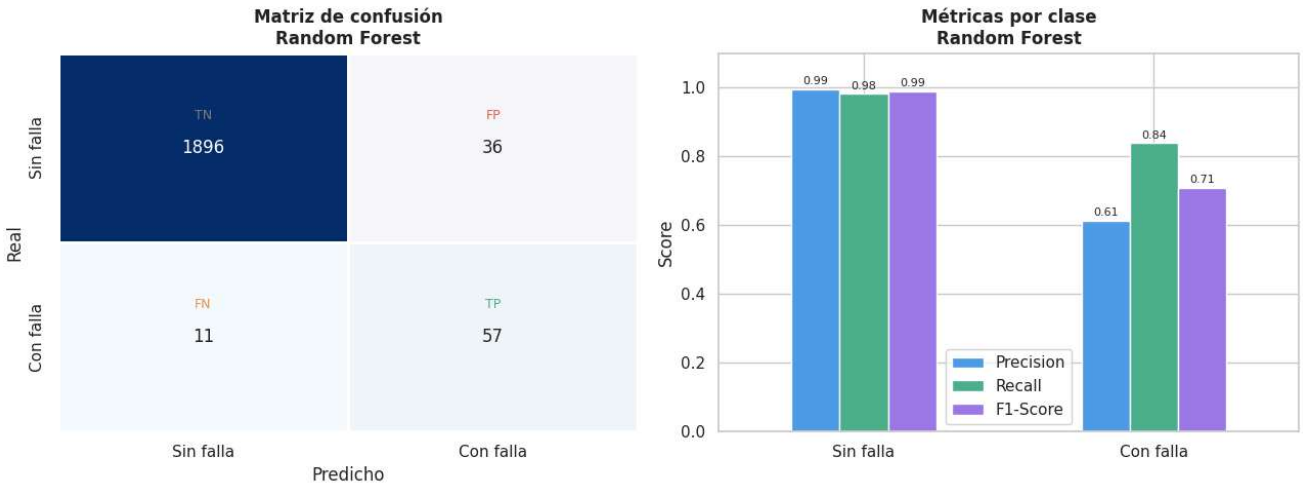


```
📊 Resumen del mejor modelo (Random Forest):
   Verdaderos Positivos (fallas detectadas) : 57
   Falsos Negativos (fallas no detectadas)  : 11  ← el más costoso
   Falsos Positivos (falsas alarmas)         : 36
```

```
if mejor_nombre in ['Random Forest', 'Gradient Boosting']:
    importancias = pd.Series(
        mejor['modelo'].feature_importances_,
        index=FEATURES
    ).sort_values(ascending=True)

    fig, ax = plt.subplots(figsize=(9, 6))
    colores_imp = ['#E85D4C' if v > importancias.quantile(0.75) else '#4C9BE8'
                   for v in importancias.values]
    importancias.plot(kind='barh', ax=ax, color=colores_imp, edgecolor='white')
    ax.set_title(f'Importancia de features — {mejor_nombre}', fontweight='bold', fontsize=13)
    ax.set_xlabel('Importancia relativa')
    ax.axvline(importancias.quantile(0.75), color='gray', linestyle='--',
               alpha=0.6, linewidth=1, label='Percentil 75')
    ax.legend()
    for i, v in enumerate(importancias.values):
        ax.text(v + 0.002, i, f'{v:.3f}', va='center', fontsize=9)
    plt.tight_layout()
    plt.savefig('09_feature_importance.png', dpi=150, bbox_inches='tight')
    plt.show()
```

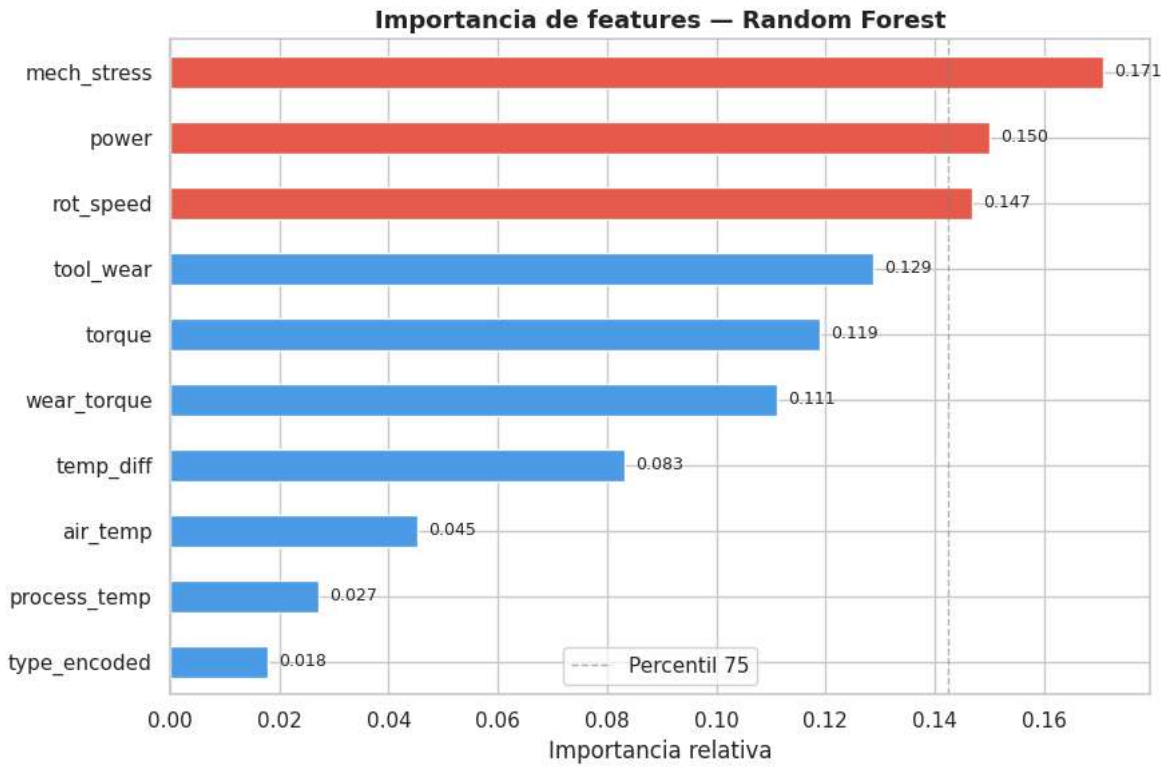

GUARDAR MODELO Y ARTEFACTOS FINALES

```
import joblib
import os

os.makedirs('modelo', exist_ok=True)

# Guardar modelo y scaler
joblib.dump(mejor['modelo'], 'modelo/random_forest_model.pkl')
joblib.dump(scaler,          'modelo/scaler.pkl')
joblib.dump(FEATURES,        'modelo/features.pkl')

print("✅ Modelo guardado en /modelo/")
print(f"   - random_forest_model.pkl")
print(f"   - scaler.pkl")
print(f"   - features.pkl")
```

```
✅ Modelo guardado en /modelo/
   - random_forest_model.pkl
   - scaler.pkl
   - features.pkl
```

```
def predecir_falla(air_temp, process_temp, rot_speed, torque, tool_wear, tipo):
    """
    Predice si una máquina está en riesgo de falla.

    Parámetros:
        air_temp     : Temperatura del aire [K]
        process_temp : Temperatura del proceso [K]
        rot_speed    : Velocidad rotacional [rpm]
        torque       : Torque [Nm]
        tool_wear    : Desgaste de herramienta [min]
        tipo         : Tipo de producto ('L', 'M', 'H')

    Retorna:
        dict con predicción, probabilidad y nivel de riesgo
    """
    type_map = {'L': 0, 'M': 1, 'H': 2}

    temp_diff   = process_temp - air_temp
    power       = torque * rot_speed
    mech_stress = torque / (rot_speed + 1)
```

```python
    wear_torque = tool_wear * torque
    type_enc    = type_map.get(tipo.upper(), 1)

    entrada = pd.DataFrame([[
        air_temp, process_temp, rot_speed, torque, tool_wear,
        temp_diff, power, mech_stress, wear_torque, type_enc
    ]], columns=FEATURES)

    entrada_sc   = scaler.transform(entrada)
    prediccion   = mejor['modelo'].predict(entrada_sc)[0]
    probabilidad = mejor['modelo'].predict_proba(entrada_sc)[0][1]

    if probabilidad >= 0.7:
        riesgo = "ALTO"
        color  = "🔴"
    elif probabilidad >= 0.4:
        riesgo = "MEDIO"
        color  = "🟡"
    else:
        riesgo = "BAJO"
        color  = "🟢"

    return {
        'prediccion':   'FALLA' if prediccion == 1 else 'NORMAL',
        'probabilidad': round(probabilidad * 100, 1),
        'riesgo':       riesgo,
        'alerta':       color
    }

print("✅ Función de predicción lista\n")

# --- Prueba con 3 escenarios reales ---
print("=" * 50)
print("PRUEBAS DE PREDICCIÓN — ESCENARIOS DE FÁBRICA")
print("=" * 50)

escenarios = [
    ("Máquina normal",        300.0, 310.5, 1550, 38.0,  80, 'M'),
    ("Posible sobrecarga",    302.5, 312.0, 1350, 62.0, 180, 'L'),
    ("Riesgo alto de falla",  304.0, 313.5, 1280, 72.0, 230, 'L'),
]

for nombre, *params in escenarios:
    resultado = predecir_falla(*params)
    print(f"\n{resultado['alerta']} {nombre}")
    print(f"   Estado      : {resultado['prediccion']}")
    print(f"   Probabilidad: {resultado['probabilidad']}%")
    print(f"   Nivel riesgo: {resultado['riesgo']}")
```

```
✅ Función de predicción lista
```